Trabajo Práctico 2: Reconstrucción 3D estéreo multivista

García, González y Turkie
I308 - Visión Artificial - Universidad de San Andrés

24 de octubre de 2026

1. Introducción

El objetivo del trabajo es obtener una nube de puntos 3D de un objeto a partir de fotografías tomadas con una cámara estéreo desde distintos puntos de vista, y medir su tamaño en milímetros. Como objeto elegimos un auto de LEGO, el Ferrari FXX K del set 42212, que mide oficialmente $29 \times 12 \times 8$ cm. Tiene buena textura, colores fuertes y un tamaño cómodo para la cámara, aunque también tiene partes negras brillantes y huecos entre piezas que complican el matching.

Armamos el dataset con una cámara estéreo ELP, que entrega imágenes de 1920×1080 por lado. Tomamos 25 pares de calibración con un checkerboard de 9×6 esquinas internas y cuadrados de 28 mm, y 15 pares del auto apoyado sobre un tablero ChArUco de 9×13 cuadrados de 42 mm con marcadores de 31,5 mm. El tablero cumple dos funciones. Define el sistema de coordenadas común a todas las vistas y, como conocemos su tamaño, sirve de regla dentro de la escena. La calibración y las fotos del auto se tomaron en días distintos, algo que después resultó central.

La Figura 1 resume el pipeline. Además de los pasos que pide la consigna agregamos cinco piezas propias, marcadas en otro color, para resolver problemas que fueron apareciendo. A lo largo del informe explicamos por qué hizo falta cada una y mostramos cuánto aporta.

2. Marco teórico

El modelo pinhole proyecta un punto $\mathbf{X}$ del espacio sobre el píxel $\mathbf{x} \sim K\,[R \mid \mathbf{t}]\,\mathbf{X}$. Los parámetros extrínsecos R y $\mathbf{t}$ dicen dónde está la cámara y hacia dónde mira, y los intrínsecos están en

$$K = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}, \tag{1}$$

con la distancia focal en píxeles y el punto principal. Una lente real además curva las rectas, sobre todo cerca de los bordes, y eso se modela con coeficientes de distorsión radial (k_1, k_2, k_3) y tangencial (p_1, p_2).

Calibrar es estimar todos esos números. Sin ellos no sabemos qué dirección del espacio corresponde a cada píxel, y sin eso no podemos triangular ni medir. Se hace fotografiando un patrón de geometría conocida, como un checkerboard. Se detectan sus esquinas y se buscan los parámetros que mejor explican dónde aparecen. Lo que el modelo no logra explicar se mide con el error de reproyección, que es la distancia en píxeles entre cada esquina detectada y la que predice el modelo, resumida como raíz del error cuadrático medio (RMS).

En la calibración estéreo se agregan los extrínsecos relativos entre las dos cámaras, que son la rotación R y la traslación $\mathbf{T}$ que llevan un punto del sistema de la cámara izquierda al de la derecha. Se estiman junto con los intrínsecos minimizando el error de reproyección en las dos cámaras a la vez. La norma $\|\mathbf{T}\|$ es la baseline, la distancia entre los centros ópticos, y como el checkerboard se mide en milímetros es lo que le da escala métrica a toda la reconstrucción.

Un píxel de la imagen izquierda no determina un punto del espacio sino todo un rayo. Ese rayo, visto desde la cámara derecha, es una recta llamada recta epipolar, así que el punto correspondiente se busca sobre una línea y no en toda la imagen. La rectificación aprovecha esto. Rota virtualmente las dos cámaras para que sus planos de imagen queden coplanares y las rectas epipolares se vuelvan filas, de modo que el correspondiente de un píxel queda en la misma fila de la otra imagen y la búsqueda pasa a ser unidimensional. Esta propiedad también sirve de diagnóstico. Si la calibración describe bien a la cámara, un mismo punto aparece a la misma altura en las dos imágenes rectificadas, y si aparece corrido verticalmente es porque la geometría de la cámara ya no es la que dice la calibración. Lo usamos en la Sección 4.4.

La disparidad $d = x_{\text{izq}} - x_{\text{der}}$ es cuánto se corre un punto entre las dos imágenes rectificadas. Por semejanza de triángulos, la profundidad es

$$Z = \frac{f\,B}{d}, \tag{2}$$

con f la focal rectificada y B la baseline. Un objeto cercano se corre mucho y uno lejano poco. La matriz Q que se obtiene al rectificar aplica esta relación y la del modelo pinhole juntas, y lleva cada (x, y, d) a un punto (X, Y, Z). Derivando la Ecuación 2 se ve qué tan sensible es la profundidad a un error en la disparidad,

$$\Delta Z \approx \frac{Z^2}{f\,B}\,\Delta d, \tag{3}$$

que crece con el cuadrado de la distancia. En nuestro caso $fB = 608{,}26 \times 59{,}09 \approx 35\,940$ px·mm. A los 27 cm a los que sacamos las fotos el tablero tiene una disparidad de unos 133 px, y cada píxel de error equivale a 2 mm de profundidad. Si la disparidad se mide con 5 px de error, apenas un 4 % de su valor y algo invisible a simple vista en un mapa de disparidad, la superficie

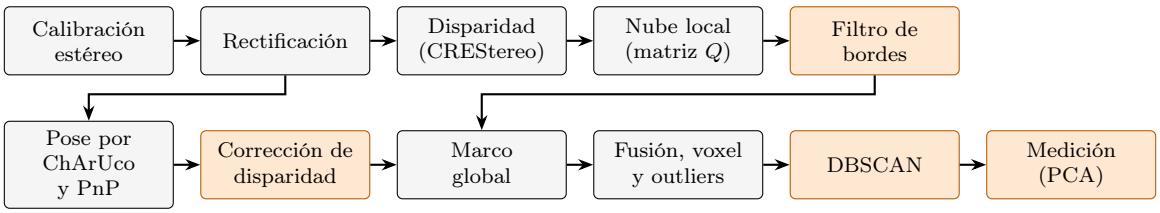


Figura 1. Pipeline implementado. En naranja están los pasos que agregamos nosotros. La pose de cada cámara se calcula sobre la imagen izquierda rectificada, que es el mismo sistema en el que se construye la nube local.

se corre 1 cm y todo lo que está a esa distancia se reconstruye un 4 % más grande. En el auto, de 29 cm de largo, eso es más de 1 cm.

Por último, cambiar de sistema de coordenadas es rotar y trasladar. Un punto del mundo se ve desde la cámara en $\mathbf{X}_{\text{cam}} = R\,\mathbf{X}_{\text{mundo}} + \mathbf{t}$, y despejando, con la transpuesta como inversa de la rotación, se vuelve al mundo con $\mathbf{X}_{\text{mundo}} = R^T(\mathbf{X}_{\text{cam}} - \mathbf{t})$. Esta última transformación, que lleva puntos del sistema de la cámara (c) al del mundo (w), se escribe como una sola matriz de 4×4,

$$T_{wc} = \begin{bmatrix} R^T & -R^T\mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix}, \tag{4}$$

que se aplica a cada punto escrito en coordenadas homogéneas como $(X, Y, Z, 1)$. La última columna de T_{wc} es la posición del centro de la cámara en el mundo, porque es adonde va a parar el origen del sistema de la cámara.

3. Metodología

3.1. Calibración y rectificación

Calibramos con la herramienta de la cátedra y usamos sus resultados tal cual. Para reportar el error de reproyección volvimos a ajustar la calibración estéreo sobre los mismos 25 pares dejando fijos los intrínsecos, lo que además da el error de cada par. La rotación y la traslación que resultan difieren de las guardadas en menos de 0,04 mm, así que el error que reportamos es el de la calibración que usa el resto del pipeline.

3.2. Disparidad

Comparamos Block Matching (BM), Semi-Global Block Matching (SGBM) y CREStereo, una red neuronal de matching estéreo que corremos con el código de la cátedra (modelo de 1280×720 con 10 iteraciones). La red trabaja a otra resolución y devuelve la disparidad escalada a la imagen completa.

Para BM y SGBM hubo que tomar una decisión. El tablero cerca de la cámara llega a 531 px de disparidad (percentil 99,9 de CREStereo), y estos métodos buscan solo dentro de un rango fijo de disparidades, con un costo que crece con ese rango. Los corrimos a media resolución con un rango de 160 px, que equivale a 320 px en la imagen completa. Es un compromiso, porque el piso más cercano queda afuera, pero el auto entra completo.

3.3. Nube local y filtro de bordes

Cada mapa de disparidad se convierte en una nube con la matriz Q, expresada en el sistema de la cámara izquierda rectificada. Descartamos los píxeles sin disparidad, los que quedan a más de 1 m (el fondo del laboratorio) y las primeras 320 columnas, una franja de la imagen izquierda que la cámara derecha no llega a ver.

El filtro de bordes es la primera pieza propia. En el borde de un objeto la disparidad salta, por ejemplo de 130 px sobre el auto a 110 px sobre el piso. CREStereo no deja huecos, así que en esos bordes suaviza el salto y produce disparidades intermedias. Cada una de ellas es un punto 3D flotando entre el auto y el piso que no existe. Vistas en 3D forman cortinas que cuelgan desde el contorno del auto hasta el piso (Figura 5).

Para eliminarlas calculamos el gradiente de la disparidad con Sobel y descartamos los píxeles donde supera 1 px de disparidad por píxel de imagen. Sobre una superficie real la disparidad cambia de a poco entre píxeles vecinos, y en un borde cambia de golpe.

3.4. Pose de cada cámara

Detectamos el ChArUco en la imagen izquierda rectificada para que la pose quede en el mismo sistema que la nube local. Por eso la matriz de cámara es la parte 3×3 de la matriz de proyección rectificada y la distorsión es nula, ya que la rectificación la corrigió.

Al principio el detector encontraba pocas esquinas porque el auto tapa parte del tablero, y una esquina del damero solo se acepta si los marcadores que la rodean también se detectan. Le pasamos la matriz K, con la que estima dónde debería estar cada esquina y la busca ahí, y bajamos a uno la cantidad de marcadores vecinos que exige. Cuando aun así quedan menos de 6 esquinas, usamos las cuatro esquinas de cada marcador detectado.

Con los pares formados por un punto del tablero y su píxel en la imagen, PnP encuentra la rotación y la traslación del tablero respecto de la cámara que mejor explican lo que se ve. La rotación sale como un vector de Rodrigues, una forma compacta de escribir una rotación con tres números. La dirección del vector es el eje de giro y su largo es el ángulo en radianes. En la vista 7, sacada desde arriba, obtuvimos $\mathbf{r} = (-0{,}09 \quad 0{,}05 \quad 0{,}20)$, que es un giro de 0,225 rad, o 12,9°, alrededor de un eje cercano al eje óptico. La cámara mira el tablero casi de frente y apenas girada. La traslación $\mathbf{t} = (-75 \quad -304 \quad 303)$ mm es dónde

ve la cámara a la esquina de origen del tablero. Con la fórmula de Rodrigues el vector se convierte en la matriz R. Como control, reproyectamos los puntos del tablero con la pose obtenida y medimos el RMS contra los detectados.

3.5. Corrección de disparidad

Esta es la pieza propia más importante y la que más trabajo nos llevó entender. En cada vista tenemos dos formas independientes de saber a qué distancia está el tablero. Una es PnP, que la deduce del tamaño conocido de sus cuadrados, y la otra es el estéreo, que la deduce de la disparidad y la baseline. Al principio no coincidían, y el estéreo daba todo más lejos y más grande (Sección 4.4).

Modelamos el error como un corrimiento constante en cada vista, $d_{\text{real}} = d_{\text{medida}} + \delta$, y lo estimamos sobre las esquinas del tablero como

$$\delta = \text{mediana}\left(\frac{fB}{Z_{\text{PnP}}} - d_{\text{medida}}\right), \tag{5}$$

donde fB/Z_{PnP} es la disparidad que debería tener cada esquina según PnP. Usamos la mediana porque algunas esquinas quedan tapadas por el auto y ahí la disparidad medida es la del auto. Después sumamos δ a todo el mapa de disparidad de esa vista, y recién entonces armamos la nube.

La diferencia nos sorprendió, porque la calibración tenía un error menor a un píxel. La explicación más probable está en cómo armamos el dataset. Las fotos de calibración y las del auto las sacamos en días distintos, y en el medio la cámara pudo haber recibido un golpe o algún movimiento que dejó las dos lentes apenas distintas de como estaban al calibrar. Si una de ellas gira un poco alrededor del eje vertical, todos los puntos de su imagen se corren horizontalmente lo mismo, y eso equivale a sumarle una constante a toda la disparidad. Con nuestra focal alcanza un giro de $5/608 \approx 0{,}5°$ para correrla 5 px. Por eso corregimos la disparidad y no escalamos la nube. En la Sección 4.4 mostramos la evidencia de este cambio y en la Figura 9 cómo mejora el auto con la corrección.

3.6. Marco global

Llevamos cada nube al sistema del tablero con la Ecuación 4. El origen queda en la esquina del tablero, con X e Y sobre su plano y Z perpendicular apuntando hacia el piso, así que el auto queda en Z negativo. Para verificar las poses dibujamos cada cámara como una pirámide en su posición.

3.7. Fusión y limpieza

Sumamos las 15 nubes y las limpiamos en cuatro pasos. Primero recortamos con una caja orientada que tiene el tamaño del tablero en planta y va de 5 mm a 15 cm de altura. Los 5 mm dejan afuera el piso, y como el auto mide 8 cm de alto, 15 cm sobra.

Tabla 1. Parámetros de la calibración estéreo.

	Izquierda	Derecha
f_x / f_y [px]	606,4 / 605,5	608,1 / 607,0
c_x / c_y [px]	954,8 / 537,5	950,6 / 527,5
k_1 / k_2	−0,002 / −0,020	0,005 / −0,025
Baseline	59,09 mm	
Rotación relativa	0,82°	
f rectificada	608,26 px	
RMS de reproyección	0,579 px	

Después submuestreamos con un voxel de 1 mm. Cada parte del auto la ven varias cámaras y aparece repetida, así que dejamos un punto por cubito de 1 mm, el promedio de los que caen adentro. Con ese tamaño se conservan detalles como las ruedas y los alerones.

El tercer paso saca los outliers estadísticos, que son los puntos cuya distancia media a sus 20 vecinos más cercanos supera en 2 desvíos a la típica.

El cuarto paso es propio. El filtro anterior saca puntos sueltos pero no grupitos, porque dentro de un grupo de 30 puntos de ruido cada uno se ve acompañado. Aplicamos DBSCAN, que agrupa los puntos conectados a menos de 3 mm (con un mínimo de 10 por grupo), y nos quedamos con el grupo más grande, porque el auto es un único objeto conexo. El radio tiene que ser mayor que el voxel para que la superficie del auto quede conectada aunque falte algún punto.

3.8. Medición

Como el auto no está alineado con el tablero, buscamos sus ejes con un PCA de los puntos en el plano XY. El primer eje es la dirección en la que el auto es más largo. Medimos el largo y el ancho sobre esos ejes y el alto desde el plano del tablero, que es Z = 0. En lugar de los puntos extremos usamos los percentiles 0,1 y 99,9, porque los extremos de una nube son justo sus peores puntos y alcanza con uno solo para arruinar la medida.

4. Resultados y discusión

4.1. Calibración y rectificación

La Tabla 1 resume la calibración. Las dos cámaras son casi iguales, con distorsión muy baja, y están separadas 59,1 mm con un ángulo relativo de 0,82°. El RMS de reproyección es de 0,579 px, con todos los pares entre 0,2 y 0,95 px (Figura 2), un error menor que un píxel que indica una buena calibración. La Figura 3 muestra un par antes y después de rectificar, donde los mismos puntos del tablero quedan sobre las mismas líneas horizontales.

4.2. Disparidad

En la Figura 4 se ve la diferencia entre los tres métodos. BM solo da disparidad en zonas con mucha textura, el 17 % de los píxeles. SGBM llega al 61 % pero deja huecos sobre el piso liso y las partes negras del auto.

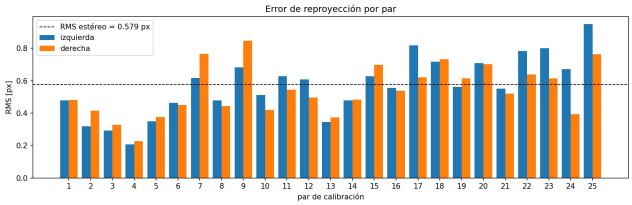


Figura 2. Error de reproyección por par de calibración, con los intrínsecos de la calibración fijos.

Tabla 2. Comparación de los métodos. La primera columna es el porcentaje de píxeles con disparidad. Las demás se miden sobre las 745 esquinas del tablero de las 15 vistas, y son la cantidad de esquinas con disparidad, el corrimiento mediano respecto de la disparidad que predice PnP y la dispersión del residuo una vez descontado el corrimiento de cada vista (1,48 veces la MAD), estas dos en píxeles.

Método	Píxeles	Esquinas	Corrim.	Disp.
BM	17 %	286 (38 %)	5,60	1,34
SGBM	61 %	681 (91 %)	5,85	1,92
CREStereo	100 %	745 (100 %)	5,49	1,94

CREStereo da disparidad en el 100 % de los píxeles, con bordes nítidos y superficies continuas. Es mucho más lento, 11 s por par en CPU contra centésimas de segundo, pero como procesamos solo 15 pares no es un problema.

Para comparar su precisión usamos las esquinas del tablero, donde PnP predice qué disparidad debería medirse (Tabla 2). Una vez descontado el corrimiento de cada vista, la dispersión es parecida en los tres, entre 1,3 y 1,9 px, y está dominada por el error de la propia referencia, ya que el RMS de PnP llega a 4 px. La diferencia real es la cobertura. BM tiene disparidad en el 38 % de las esquinas, SGBM en el 91 % y CREStereo en todas. Las esquinas son además el caso más fácil, con mucho contraste, y sobre el piso liso o las piezas negras la ventaja de la red es todavía mayor. Por eso elegimos CREStereo.

La contracara de no dejar huecos es que la red también completa donde no debería, en los bordes. La Figura 5 muestra la nube de la vista 7 sobre el auto con y sin el filtro de bordes. Sin filtro, las cortinas cuelgan desde todo el contorno del auto hasta el piso. El filtro saca el 9 % de los puntos de esa zona, que son justamente las cortinas, y conserva las superficies.

4.3. Poses de las cámaras

Las 15 vistas tienen pose (Tabla 3). En 13 se resolvió con esquinas del damero, y en las vistas 0 y 10, tomadas a ras del piso y con el auto tapando el tablero, con las esquinas de los marcadores. Ajustar el detector casi duplicó las esquinas encontradas en 13 de las 15 vistas, que pasaron de 16–33 a 30–67. La excepción es la vista 10, donde el detector ajustado no encontró ninguna y el de fábrica 19. Ahí el respaldo por marcadores funcionó igual, con 68 puntos. El RMS de PnP va de 1,1 a 4,0 px. Es más alto que el de la calibración, probablemente porque el tablero, de papel y apoyado sobre un cartón, no es perfectamente plano.

La Figura 6 muestra los ejes del tablero dibujados con cada pose. X e Y quedan apoyados sobre el tablero y Z perpendicular. La Figura 7 muestra las 15 cámaras en el marco global, a entre 23 y 31 cm del centro del tablero y apuntando al auto desde distintas alturas, que es como sacamos las fotos.

4.4. El problema de escala y su corrección

La primera versión del pipeline daba una nube que se veía perfecta pero medía de más. Para encontrar la causa medimos el tablero con el estéreo. Triangulamos sus esquinas con la disparidad y comparamos las distancias entre ellas con las reales. En todas las vistas el estéreo daba el tablero entre un 3,1 y un 8,6 % más grande, y su plano entre 2 y 12 mm por debajo de donde lo ubica PnP (columnas de antes en la Tabla 3).

El error no viene de la red. En las esquinas del tablero los tres métodos de disparidad tienen el mismo corrimiento mediano respecto de PnP, de 5,6, 5,9 y 5,5 px para BM, SGBM y CREStereo (Tabla 2). Tampoco viene de PnP, que solo usa la K y el tamaño del tablero y da un RMS bajo.

Además es un corrimiento y no una escala. En la Figura 8 cada punto es una esquina del tablero, con la disparidad que predice PnP en el eje horizontal y la diferencia contra la medida en el vertical. Si el problema fuera una baseline mal calibrada, el error sería proporcional a la disparidad y los puntos seguirían la línea punteada. En cambio forman una banda entre 3 y 10 px que no crece con la disparidad, que es lo que produce un giro mínimo de una cámara respecto de la otra.

Que la cámara cambió entre la calibración y las fotos se ve en la propia rectificación. En los 25 pares de calibración, la diferencia vertical entre la misma esquina en las dos imágenes rectificadas tiene media 0,00 px y mediana en valor absoluto de 0,24 px. En las capturas, con el mismo cálculo sobre las esquinas del ChArUco, la media es −0,56 px y la mediana 0,83 px. Una media distinta de cero es un corrimiento sistemático, que solo aparece si la pose relativa entre las cámaras ya no es la calibrada. Nuestra hipótesis es que un golpe giró levemente una de las dos cámaras, alrededor de 0,5° en horizontal y unos 0,05° en vertical. Que el corrimiento no sea igual en todas las vistas (de 3,4 a 7,2 px) sugiere además que el rig no es del todo rígido mientras se lo manipula, y es la razón para estimar uno por vista.

Con la corrección, la escala del tablero pasa a estar entre 1,000 y 1,014 y su plano queda a ±0,3 mm de $Z = 0$ en todas las vistas. La corrección solo fija la mediana de la disparidad, así que nada garantizaba que la escala y la altura también se arreglaran. Que lo hagan confirma que el modelo de corrimiento es el correcto. En el auto la mejora se ve a simple vista (Figura 9). Sin corregir, cada vista lo reconstruye con un tamaño distinto, así que las copias no coinciden y el auto queda borroneado, más largo que la caja de las medidas



Figura 3. Par de captura 0 antes (arriba) y después (abajo) de rectificar. Las líneas horizontales ayudan a comparar alturas. Después de rectificar, cada esquina del tablero queda en la misma fila en las dos imágenes.

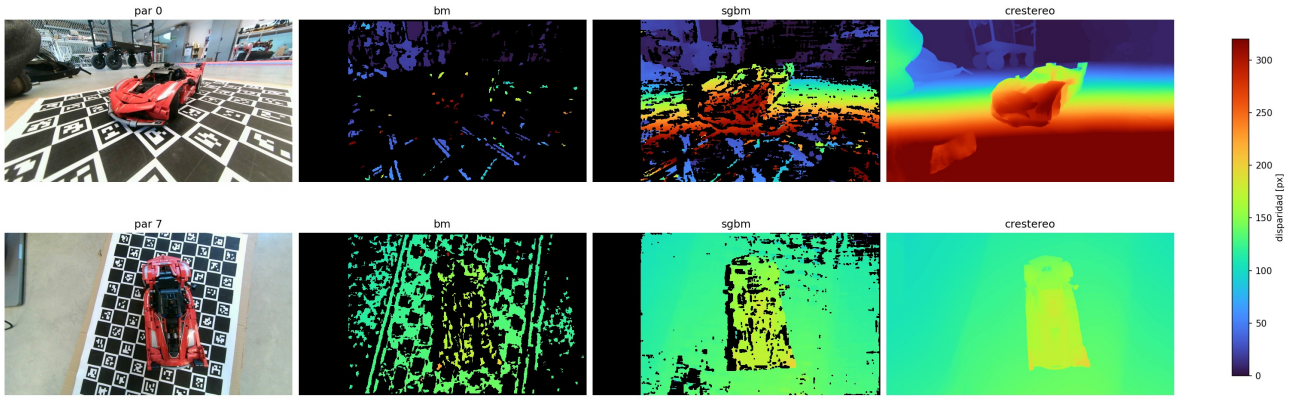


Figura 4. Mapas de disparidad de los tres métodos en una vista baja (par 0) y una cenital (par 7). En negro están los píxeles sin disparidad. La franja negra de la izquierda en BM y SGBM es la zona que la cámara derecha no ve.



Figura 5. Nube de la vista 7 recortada al auto, sin filtro de bordes (arriba) y con filtro (abajo). Las cortinas de puntos que bajan desde el contorno del auto son disparidades interpoladas en los bordes.

oficiales y hundido hacia el piso. Con la corrección las vistas se superponen y el auto entra en la caja.

La consigna propone ICP para mejorar el encaje entre nubes, y en nuestro caso no hace falta. Lo probamos alineando cada vista contra la unión de las otras 14. La distancia mediana de cada punto a la nube del resto baja de 0,61 a 0,56 mm en promedio, menos que el voxel de 1 mm, y la rotación que aplica ICP es de 0,2 a 1°. Las poses de PnP ya son globalmente consistentes porque todas se calculan contra el mismo tablero, y los errores no se acumulan de una vista a la otra. La Figura 10 lo muestra visualmente con tres vistas muy distintas, pintadas de colores, que caen sobre el mismo auto.

4.5. Fusión y limpieza

La Figura 11 muestra la nube en cada etapa y la Tabla 4 los puntos que quedan. El voxel reduce la nube 9 veces. Varias vistas ven la misma zona y, además, a 27 cm un píxel cubre menos de medio milímetro, así que cada vista ya aporta varios puntos por milímetro cuadrado. Los outliers estadísticos y DBSCAN sacan entre los dos menos del 1,1 % de los puntos, pero son los que más pesan en la medición. La astilla vertical que se ve sobre el auto y los fragmentos sueltos a los costados son puntos extremos, y cualquiera de ellos alcanza para estirar una medida, como muestra la ablación de la Sección 4.6.

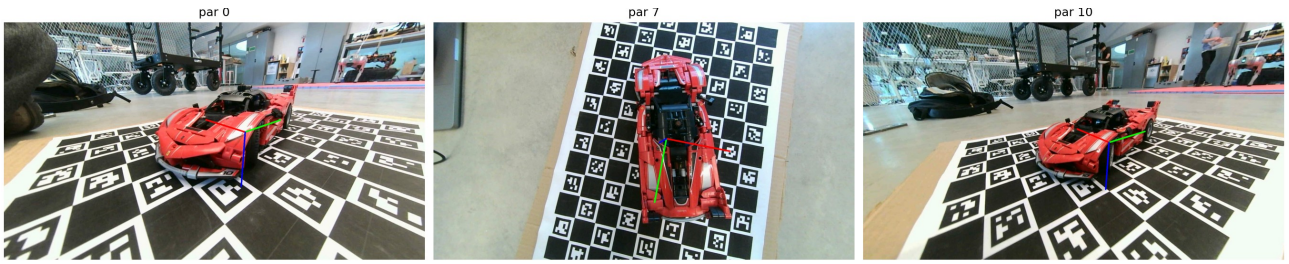


Figura 6. Ejes del tablero (X rojo, Y verde, Z azul) proyectados con la pose estimada y dibujados en el centro del tablero. Las vistas 0 y 10 son las que se resolvieron con las esquinas de los marcadores.

Tabla 3. Resultados por vista. Las columnas de esquinas indican cuántas esquinas del damero encuentran el detector de fábrica y el ajustado. La fuente es C cuando la pose sale de las esquinas del damero y M cuando sale de las de los marcadores. La escala es el cociente entre las distancias entre esquinas trianguladas con estéreo y las reales, y la altura del tablero es la altura mediana de esas esquinas en el sistema del tablero, que debería ser 0 (positiva por debajo del tablero).

	Esquinas						Escala		Altura [mm]		
Vista	Fábrica	Ajust.	Fuente	Puntos	RMS [px]	Dist. [mm]	Antes	Después	Antes	Después	δ [px]
0	0	0	M	48	3,98	255	1,044	1,014	2,9	0,2	5,37
1	24	44	C	44	2,19	233	1,051	1,012	6,1	0,0	5,49
2	22	52	C	52	2,37	291	1,073	1,001	7,9	0,1	6,76
3	29	53	C	53	1,92	284	1,086	1,008	11,7	−0,1	7,15
4	25	49	C	49	1,68	292	1,061	1,000	7,5	−0,3	6,23
5	22	49	C	49	2,22	295	1,063	1,001	5,6	−0,2	5,43
6	17	42	C	42	2,20	231	1,059	1,008	6,9	−0,1	6,86
7	32	67	C	67	1,09	275	1,043	1,000	11,2	0,0	5,42
8	33	55	C	55	1,62	312	1,076	1,002	8,9	−0,2	6,30
9	16	30	C	30	1,58	255	1,031	1,007	2,2	0,1	3,44
10	19	0	M	68	2,87	300	1,038	1,002	3,3	−0,1	5,14
11	16	44	C	44	1,83	304	1,046	1,002	4,3	0,0	4,74
12	16	38	C	38	1,99	264	1,041	1,012	3,1	−0,1	4,01
13	18	47	C	47	2,01	238	1,036	1,005	3,9	0,0	4,04
14	30	59	C	59	1,23	249	1,038	1,004	7,4	0,0	4,13



Figura 7. Las 15 nubes en el marco global vistas desde arriba, con una pirámide por cámara. Los ejes de colores marcan el origen, en la esquina del tablero.

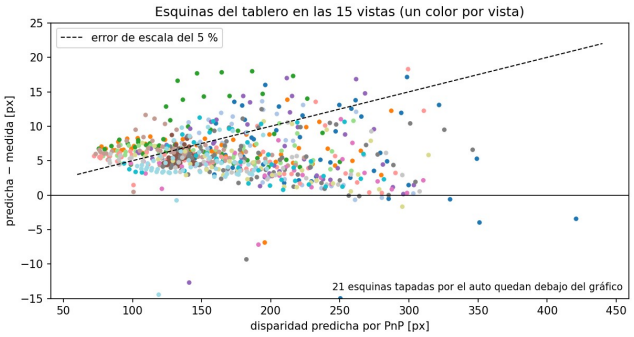


Figura 8. Diferencia entre la disparidad que predice PnP y la que mide CREStereo en las esquinas del tablero de las 15 vistas. Los puntos forman una banda que no sigue la pendiente de un error de escala (línea punteada). Las esquinas tapadas por el auto dan diferencias muy negativas y no se muestran.

4.6. Medición

El auto mide 291,5 × 129,0 × 79,9 mm contra los 290 × 120 × 80 mm oficiales, con errores de +0,5 %, +7,5 % y −0,1 % (Figura 12). Para saber cuánto aporta cada decisión, rearmamos el auto con cada paso apagado (Tabla 5).

Sin la corrección, el largo crece un 3 % pero el alto baja un 3 %. Si el error fuera solo de escala, todo crecería por igual. Lo que pasa es que el corrimiento empuja cada punto lejos de su cámara a lo largo de su rayo, y más cuanto más lejos está (Ecuación 3). Visto desde cámaras que miran el auto desde arriba, eso lo estira en planta y lo hunde hacia el piso.

Sin el filtro de bordes, el ancho se pasa un 28 % porque las cortinas están justo en el contorno. El umbral no es crítico. Con 0,5 px/px la medida casi no cambia y se pierde un 18 % más de puntos, y con 2 px/px pa-

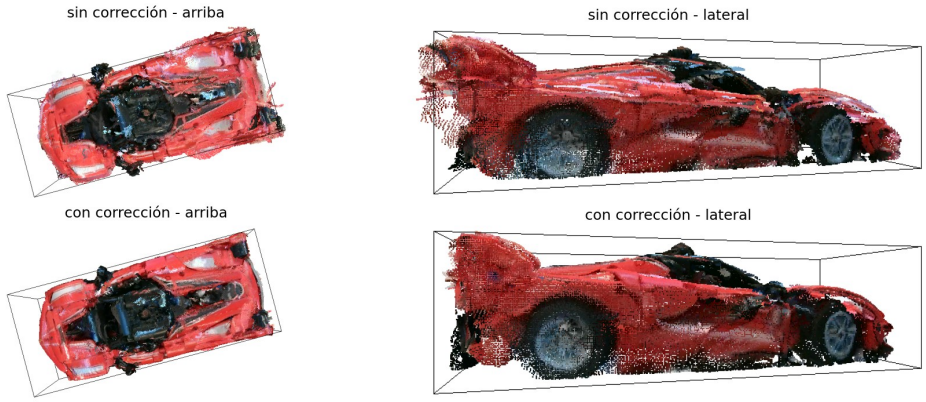


Figura 9. Auto fusionado sin corrección de disparidad (arriba) y con corrección (abajo), visto desde arriba y de costado. La caja negra tiene las medidas oficiales, 290 × 120 × 80 mm.



Figura 10. Vistas 0 (rojo), 7 (verde) y 10 (azul) en el marco global, sin el piso, desde arriba y de costado. Si alguna pose estuviera mal se vería un auto de un color corrido respecto de los otros.

Tabla 4. Puntos que sobreviven a cada etapa de la fusión.

Etapa	Puntos	Quedan
Recorte (15 vistas)	2 763 947	—
Voxel de 1 mm	303 151	11,0 %
Outliers estadísticos	302 090	99,6 %
DBSCAN	299 841	99,3 %

san más puntos de borde y el largo ya crece un 1,7 %. Elegimos 1, el valor más permisivo que no cambia la medida.

Sin DBSCAN, el largo se va un 43 % de más, porque quedan grupos de ruido lejos del auto que el filtro estadístico no reconoce como outliers.

El recorte de percentiles es la decisión más delicada. Sin recorte, unos pocos puntos sueltos inflan todo. Con 0,5 % o más empieza a comerse el auto mismo, porque 0,5 % de 300 000 puntos son 1 500 puntos por lado y la trompa y el alerón son partes finas con pocos puntos. Con 0,1 %, unos 300 puntos por lado, se van los sueltos y el auto queda entero.

El ancho es la medida menos confiable. Es la única que queda por encima del valor oficial con cualquier recorte. Tiene sentido, porque los costados del auto se ven siempre de forma rasante, que es donde la disparidad es menos confiable y donde quedan los restos de cortinas que el filtro no llega a sacar, visibles debajo de las ruedas en la vista lateral de la Figura 12. Hay que tener en cuenta además que la medida oficial está redondeada al centímetro. Que diga 12 cm puede significar cualquier valor entre 115 y 125 mm, y con 125 mm el error sería del 3 %.

Tabla 5. Ablación. Medición en mm, con el error relativo en % entre paréntesis, con un paso del pipeline apagado o cambiado. Debajo, el pipeline completo con distintos recortes de percentiles.

Variante	Largo	Ancho	Alto
Completo	291,5 (+0,5)	129,0 (+7,5)	79,9 (−0,1)
Sin corrección	299,1 (+3,2)	139,9 (+16,6)	77,5 (−3,1)
Sin filtro de bordes	312,6 (+7,8)	153,1 (+27,6)	79,9 (−0,1)
Sin DBSCAN	416,2 (+43,5)	144,2 (+20,2)	80,7 (+0,9)
Gradiente $< 0{,}5$	291,0 (+0,4)	128,7 (+7,3)	80,4 (+0,4)
Gradiente < 2	294,9 (+1,7)	129,5 (+8,0)	79,9 (−0,1)
Recorte 0 %	298,7 (+3,0)	140,4 (+17,0)	84,1 (+5,1)
Recorte 0,5 %	284,2 (−2,0)	125,6 (+4,7)	77,5 (−3,1)
Recorte 1 %	278,8 (−3,9)	124,1 (+3,4)	75,7 (−5,3)

4.7. Limitaciones

La parte de abajo del auto y las caras internas de las ruedas no las ve ninguna cámara, así que no están en la nube. Fuera del tablero el piso sale levemente curvado en los bordes de la imagen, un residuo de calibración en la periferia que no afecta al auto porque queda en el centro. La corrección de disparidad necesita que el tablero se vea en cada foto, aunque eso ya era un requisito para calcular la pose. Por último, el auto no es un objeto ideal, porque tiene huecos entre las piezas y partes negras brillantes donde cualquier método de matching sufre.

5. Conclusiones

Obtuvimos una nube de 300 000 puntos del auto en la que el largo y el alto quedan a menos del 0,5 % del tamaño real y el ancho un 7,5 % por encima. El trabajo además nos dejó varias lecciones que no eran evidentes al empezar.

La más importante es que una calibración describe a la cámara tal como estaba el día en que se hizo. La nuestra cambió entre la calibración y las fotos, y nada en las imágenes lo delataba porque la nube se veía perfecta. El síntoma estaba en el corrimiento vertical después de rectificar, que pasó de 0,24 a 0,83 px y que

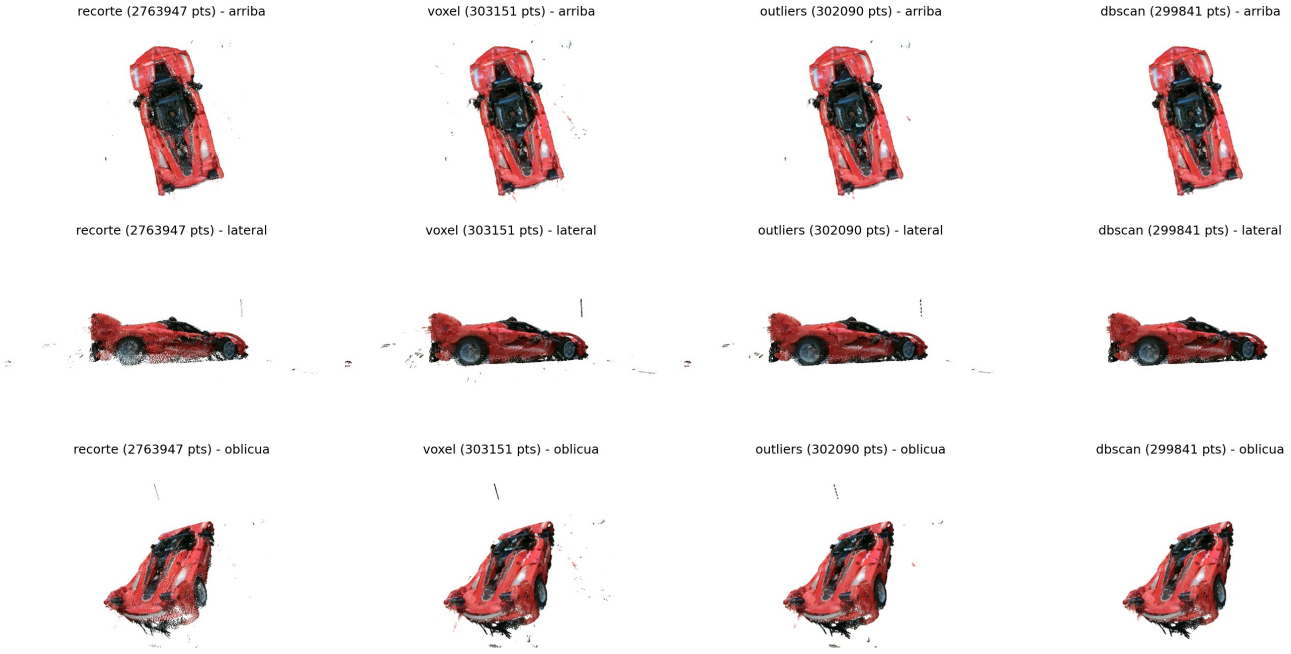


Figura 11. La nube fusionada en cada etapa de la limpieza (columnas) desde tres puntos de vista (filas). La columna del recorte muestra uno de cada diez puntos.

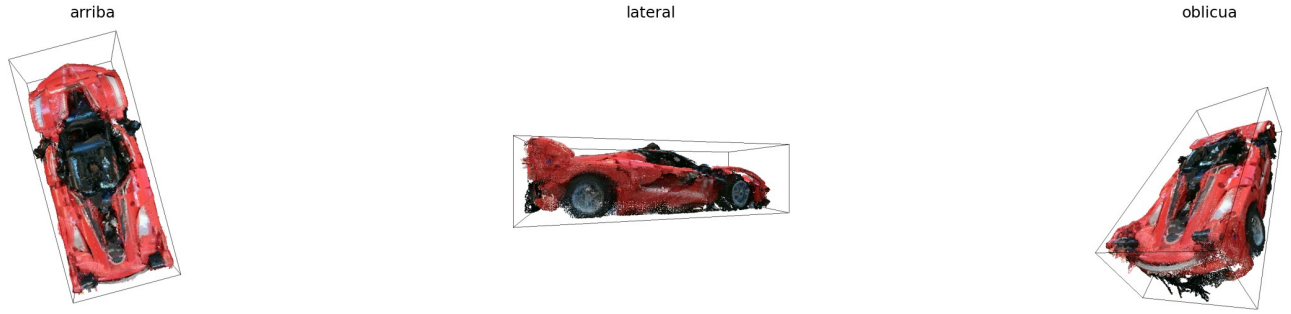


Figura 12. Nube final con la caja de medición, orientada según los ejes del PCA, con el largo y el ancho entre los percentiles 0,1 y 99,9 y el alto desde el plano del tablero.

no se ve si no se lo busca. Es un control barato que conviene hacer antes de reconstruir.

El estéreo con baseline corta es muy sensible. Como el error de profundidad crece con $Z^2/(fB)$, con 6 cm de baseline y a 27 cm de distancia cada píxel de disparidad son 2 mm. Un giro de medio grado entre las cámaras alcanzó para agrandar la reconstrucción hasta un 8 %.

Tener dos fuentes de escala independientes fue lo que destapó el problema. La baseline y el tablero miden lo mismo por caminos distintos, y con una sola el error hubiera pasado inadvertido. El tablero, que en principio estaba para definir el sistema común, terminó sirviendo también para corregir la calibración sin repetir las fotos.

Un corrimiento constante en la disparidad deforma la escena de forma despareja, y el auto salía más largo pero más bajo. Escalar la nube no lo habría arreglado, así que hubo que corregir el error donde se originaba, en la disparidad.

Que la red dé disparidad en todos los píxeles también tiene un costo. Completa los bordes donde no debería, y esos puntos inventados inflan la medición. Sin el filtro de bordes el ancho se pasaba un 28 %.

Las medidas se toman en los extremos de la nube, que son justo sus peores puntos, así que dependen más de los pocos puntos del contorno que de los 300 000 del interior. Por eso hacen falta criterios robustos, como DBSCAN y los percentiles, y por eso también el ancho, que se mide sobre los costados vistos de forma rasante, es la medida menos confiable.

ICP no hizo falta. Como cada pose se calcula contra el mismo tablero, los errores no se acumulan de una vista a la otra, y ICP mejoró el encaje en solo 0,05 mm.

Con el detector de ChArUco aprendimos a no depender de una sola configuración. Pasarle la K casi duplicó las esquinas encontradas, pero en la vista 10 no encontró ninguna, y ahí la pose salió del respaldo por marcadores.

Si tuviéramos que repetir el trabajo, calibraríamos el mismo día que sacamos las fotos o, mejor, con el ChArUco ya presente en las escenas de captura, de forma que la propia captura sirva para verificar la calibración.